UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
PPGEEC2328 - TÓPICOS ESPECIAIS EM PROCESSAMENTO EMBARCADO E DISTRIBUÍDO
PROF. DR. RICARDO VALENTIM

APLICAÇÃO DE TÉCNICAS DE INTELIGÊNCIA ARTIFICIAL PARA DESENVOLVIMENTO DE SISTEMA PARA ANÁLISE DE LESÕES E SUPORTE À DECISÕES CLÍNICAS

RELATÓRIO DE EXECUÇÃO

ERNANE FERREIRA ROCHA JUNIOR
ANTONIO DE OLIVEIRA NUNES COSTA

NATAL/RN, 11 DE NOVEMBRO DE 2025

SUMÁRIO

1. INTRODUÇÃO 3
2. METODOLOGIA 4
2.1. Fonte de Dados (Dataset) 4
2.1.1. Dados de Localização 4
2.1.2. Mapa Corporal (Body Map) 5
Imagem 1: Numeração - Pé direito 5
Imagem 2: Numeração - Mão Esquerda 5
2.2. Preparação do Ambiente e Dados 5
2.3. Arquitetura do Modelo: VGG16 com Transfer Learning 6
Imagem 3: Representação das Camadas da arquitetura da VGG16 6
2.4. Transfer Learninig e Fine-Tuning 7
2.5. Software 7
Imagem 4: Diagrama do Banco de dados 8
3. RESULTADOS 10
3.1. Modelo de Classificação 10
3.1.1. Treinamento com Transfer Learning (TL) por 50 Épocas 10
Imagem 5: Acurácia (esquerda) e Perda (direita) do modelo ao logo das épocas para o modelo Baseline 10
Imagem 6: Matriz de Confusão 11
3.1.2. Extensão do Treinamento até 94 Épocas 12
Imagem 7: Acurácia (esquerda) e Perda (direita) do modelo ao logo das épocas para o modelo File-Tuned 12
Imagem 8: Matriz de Confusão 13
Imagem 9: Matriz de Confusão Normalizada 13
3.1.3. Fine-Tuning Descongelando as Últimas Camadas da VGG16 13
3.1.4. Procedimentos de exportação e decisão operacional 14
3.2. O Sistema de Análise de Lesões por Pressão 15
Imagem 10: Tela inicial - Listagem de Pacientes Existentes 15
Imagem 11: Formulário de Cadastro de Novo Paciente - Informações Básicas 16
Imagem 12: Formulário de Cadastro de Novo Paciente - Imagens das Lesões 16
Imagem 13: Tela de Chat de Um Paciente Aberta 17
Imagem 14: Exemplo de pré-laudo (pdf) gerado - Página 1 17
Imagem 15: Exemplo de pré-laudo (pdf) gerado - Página 2 17
Imagem 16: Exemplo de pré-laudo (pdf) gerado - Página 3 17
4. Conclusão 19
5. Referências 20

1. INTRODUÇÃO

O diagnóstico preciso e rápido de lesões de pele é um desafio significativo na prática clínica, com um impacto direto na qualidade do tratamento e na vida dos pacientes. A classificação incorreta pode levar a tratamentos inadequados, retardando a cicatrização e aumentando os custos para o sistema de saúde.

Com o avanço do Deep Learning, surgiram novas oportunidades para automatizar e aprimorar a análise de imagens médicas. Redes neurais convolucionais (CNNs), em particular, demonstraram alta eficácia na classificação de imagens, superando em alguns casos a precisão de especialistas humanos.

Este trabalho se insere nesse contexto, propondo um sistema de apoio à decisão clínica (IA-CDSS) que utiliza o modelo VGG16, pré-treinado com o vasto dataset ImageNet, para classificar diferentes tipos de lesões cutâneas. A abordagem combina Transfer Learning, para aproveitar o conhecimento prévio do modelo, e Fine-Tuning, para especializá-lo na tarefa específica de classificação de lesões.

2. METODOLOGIA

2.1. Fonte de Dados (Dataset)

O estudo utilizou o dataset público "Multi-modal wound classification using images and locations", disponível no GitHub. O conjunto de dados foi coletado ao longo de um período clínico de dois anos no Centro de Feridas e Vasculares AZH em Milwaukee, Wisconsin. O conjunto de dados inclui 730 imagens de
feridas em formato .jpg. As imagens têm tamanhos variados, com largura variando de 320 a 700 pixels e altura de 240 a 525 pixels. Essas imagens contêm quatro tipos diferentes de feridas: venosas, diabéticas, por pressão e cirúrgicas.

Um iPad Pro (versão do software 13.4.1) e uma câmera digital Canon SX 620 HS foram usados para capturar as imagens, e a rotulagem foi feita por um especialista em feridas do Centro de Feridas e Vasculares AZH. Na maioria dos casos, cada imagem foi tirada de um paciente diferente. No entanto, há alguns casos em que várias fotos foram tiradas do mesmo paciente em diferentes partes do corpo ou em diferentes estágios de cicatrização. Nesses últimos casos, os formatos das feridas são diferentes, portanto, são consideradas imagens separadas. As imagens são divididas em quatro classes principais de lesões:

Classe	Significado (EN)	Significado apx. (PT-BR)
D	Diabetic Foot Ulcer	Úlcera do Pé Diabético
P	Pressure Ulcer	Úlcera por Pressão
S	Surgical Wound	Ferida Cirúrgica
V	Venous Leg Ulcer	Úlcera Venosa da Perna
N	Normal Skin	Pele Normal
BG	Background	Fundo

Adicionalmente, foram incluídas as classes Normal Skin (N) e Background (BG) para aumentar a robustez do modelo, permitindo-lhe diferenciar lesões de pele saudável e ignorar o fundo da imagem.

2.1.1. Dados de Localização

Os arquivos *wound_locations_Labels_AZH_Train.csv* e *wound_locations_Labels_AZH_Test.csv* contêm informações sobre a localização das imagens. O campo *index* identifica cada imagem (por exemplo, BG/1 ou D/10), enquanto *Locations* representa um valor inteiro correspondente a uma região específica do corpo. O valor -1 indica a ausência de uma localização corporal definida e é utilizado em classes não-lesivas, como Fundo (BG) ou Pele Normal (N), que podem se originar de qualquer região. Já os números positivos (por exemplo, 131, 132, etc.) correspondem a regiões específicas do *body map* (mapa corporal). Por fim, o campo *Labels* representa a classe de lesão ou não-lesão, identificada por um número. Os rótulos 0, 1, 2, 3, 4, 5, entre outros, são utilizados em uma classificação multiclasse das

lesões.

2.1.2. Mapa Corporal (Body Map)

A fonte de dados também é composta pelo mapa corporal desenvolvido para indexar a localização das lesões. Os arquivos *PNG* apresentam esse mapa dividido visualmente em regiões, enquanto os arquivos PDF (*Labels*) funcionam como tabelas de referência que relacionam o Número de Localização, que é correspondente ao valor presente na coluna *Locations* dos arquivos CSV, ao Nome da Localização, como por exemplo "Right Distal Plantar First Toe". Abaixo, é apresentado um exemplo da numeração utilizada para o pé direito e a mão esquerda.

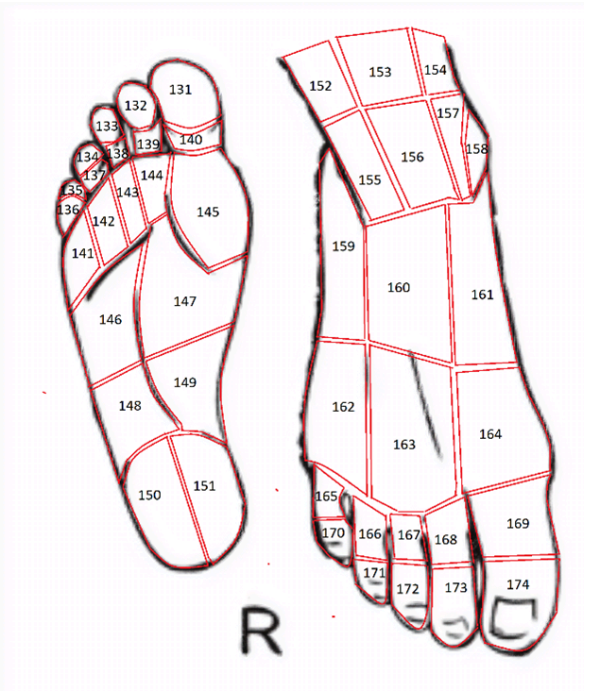

Imagem 1: Numeração - Pé direito

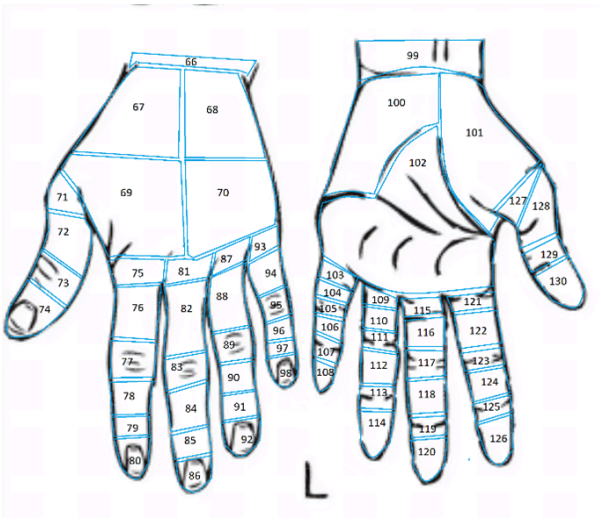

Imagem 2: Numeração - Mão Esquerda

2.2. Preparação do Ambiente e Dados

Ignoramos as informações de localização (*Locations* do CSV) e focamos apenas nas imagens, seguindo a mesma abordagem do modelo WIC. Utilizamos todas as classes de lesões e incluímos também as classes não-lesivas, com o objetivo de criar um classificador robusto, capaz de identificar se uma imagem representa uma lesão ou apenas pele normal/fundo.

Definimos como classes-alvo as categorias D (Diabética), P (Pressão), S (Cirúrgica) e V (Venosa), e como classes de suporte as categorias N (Pele Normal) e BG (Fundo).

Na preparação dos dados, mapeamos as imagens (por exemplo, BG/1.jpg, D/10.jpg, etc.) para seus respectivos rótulos de classe (BG, D, N, P, S e V). Utilizamos as imagens da pasta *Train* para o treinamento e as da pasta *Test* para a avaliação do modelo.

Configuramos um *notebook* no *Google Colaboratory*, utilizando runtime Python 3 com GPU T4 como acelerador de hardware e a versão mais recente do runtime (2025.10). A versão do TensorFlow utilizada foi a 2.19.0.

Carregamos os dados no *Google Drive* para facilitar o acesso e a organização. O conjunto foi dividido em treino (234 imagens, 6 classes) e teste (696 imagens, 6 classes). Como o dataset original contém um número reduzido de imagens de ROI (apenas 730 imagens no conjunto AZH), aplicamos técnicas de Data Augmentation, incluindo rotação, inversão e variação de escala, exclusivamente sobre o conjunto de treino, com o objetivo de aumentar a diversidade dos dados e reduzir o risco de overfitting.

2.3. Arquitetura do Modelo: VGG16 com Transfer Learning

A arquitetura VGG16 é uma rede neural convolucional (CNN) profunda, reconhecida por sua simplicidade e eficácia na extração de características de imagens.

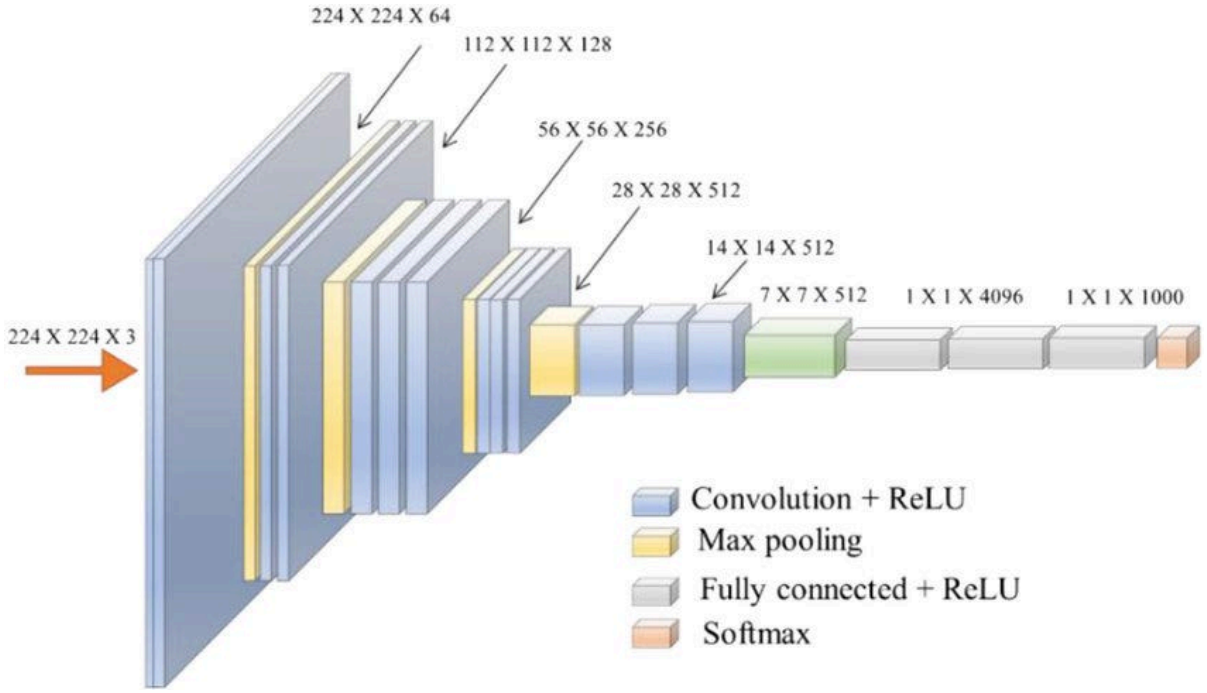

Imagem 3: Representação das Camadas da arquitetura da VGG16

Nesta abordagem, foi empregada a estratégia de Transfer Learning, iniciando pelo carregamento do modelo pré-treinado com os pesos obtidos no dataset ImageNet, exceto pela camada de classificação final. Em seguida, realizou-se o congelamento das camadas convolucionais do modelo, de modo que seus pesos não fossem atualizados durante o treinamento inicial — preservando, assim, o conhecimento genérico de extração de características, como bordas, texturas e formas, adquirido a partir de milhões de imagens. Por fim, foi realizada a adição de um novo cabeçalho de classificação (topo), composto por camadas densas (fully connected), adaptando o modelo à tarefa específica de classificação em seis classes.

2.4. Transfer Learninig e Fine-Tuning

Realizamos o treinamento do modelo utilizando a técnica de Transfer Learning com a arquitetura VGG16, reconhecida por ser eficiente na extração de características visuais. Carregamos a rede com pesos pré-treinados no *ImageNet*, removendo a camada densa final para adaptá-la ao nosso problema de classificação em seis classes. As primeiras 18 camadas convolucionais (de *block1_conv1* até *block5_pool*) foram mantidas com os pesos originais, preservando o conhecimento adquirido em tarefas de visão computacional genérica.

Em seguida, congelamos as camadas convolucionais da base *VGG16* para evitar que os pesos pré-treinados fossem modificados durante o treinamento inicial. Sobre essa base, adicionamos um novo cabeçalho de classificação, composto pela aplanagem da saída convolucional, uma camada densa de 512 neurônios com ativação *ReLU*, camada de *dropout* para regularização, uma segunda camada densa com ativação *ReLU* e, por fim, a camada de saída com ativação *softmax*, responsável por classificar as imagens nas seis categorias.

Combinamos esse novo cabeçalho à base convolucional e compilamos o modelo utilizando uma taxa de aprendizado reduzida (0.00001) para o processo de *fine-tuning*, juntamente com a função de perda categórica (*categorical cross-entropy*), apropriada para classificação multiclasse com *one-hot encoding*. A configuração resultou em aproximadamente 27,7 milhões de parâmetros, dos quais 12,9 milhões foram treináveis e 14,7 milhões permaneceram congelados.

Durante o treinamento, utilizamos *callbacks* para *checkpointing* e *early stopping*, salvando automaticamente o melhor modelo de acordo com a acurácia de validação. Definimos um critério de paciência de 10 épocas, interrompendo o treinamento caso não houvesse melhora no desempenho dentro desse intervalo. Essa configuração garantiu estabilidade, eficiência e preservação dos melhores pesos obtidos ao longo do processo de aprendizado.

2.5. Software

Desenvolvemos uma aplicação modular com o objetivo de integrar o modelo de classificação de lesões cutâneas baseado em Deep Learning e um modelo de linguagem (LLM), compondo um Sistema de Apoio à Decisão Clínica (IA-CDSS) voltado para análise automatizada e explicável de feridas. A arquitetura do sistema foi organizada em três módulos principais: *backend*, *Streamlit* e *worker*, orquestrados por meio do *Docker* para garantir isolamento, escalabilidade e portabilidade entre ambientes.

Configuramos quatro serviços principais: *PostgreSQL*, *Redis*, *Streamlit* e *Worker*. O *PostgreSQL* foi utilizado como banco de dados relacional para armazenamento de informações dos pacientes, registros de processamento e metadados das imagens. O Redis atuou como *message broker* para gerenciamento de tarefas assíncronas, enquanto o *Worker* (implementado com *Celery*) foi responsável pelo processamento em *background*, executando as rotinas essenciais de classificação de imagens e geração automatizada de relatórios. O *Streamlit* foi adotado para o desenvolvimento da interface interativa, permitindo o uso da aplicação em navegadores de dispositivos móveis, tablets e desktops.

A estrutura do banco de dados foi projetada para registrar os pacientes, suas imagens associadas, resultados de classificação e histórico de interações. Essa modelagem seguiu princípios de

normalização e relacionamentos consistentes, conforme ilustrado no Diagrama de Banco de Dados (Imagem 4).

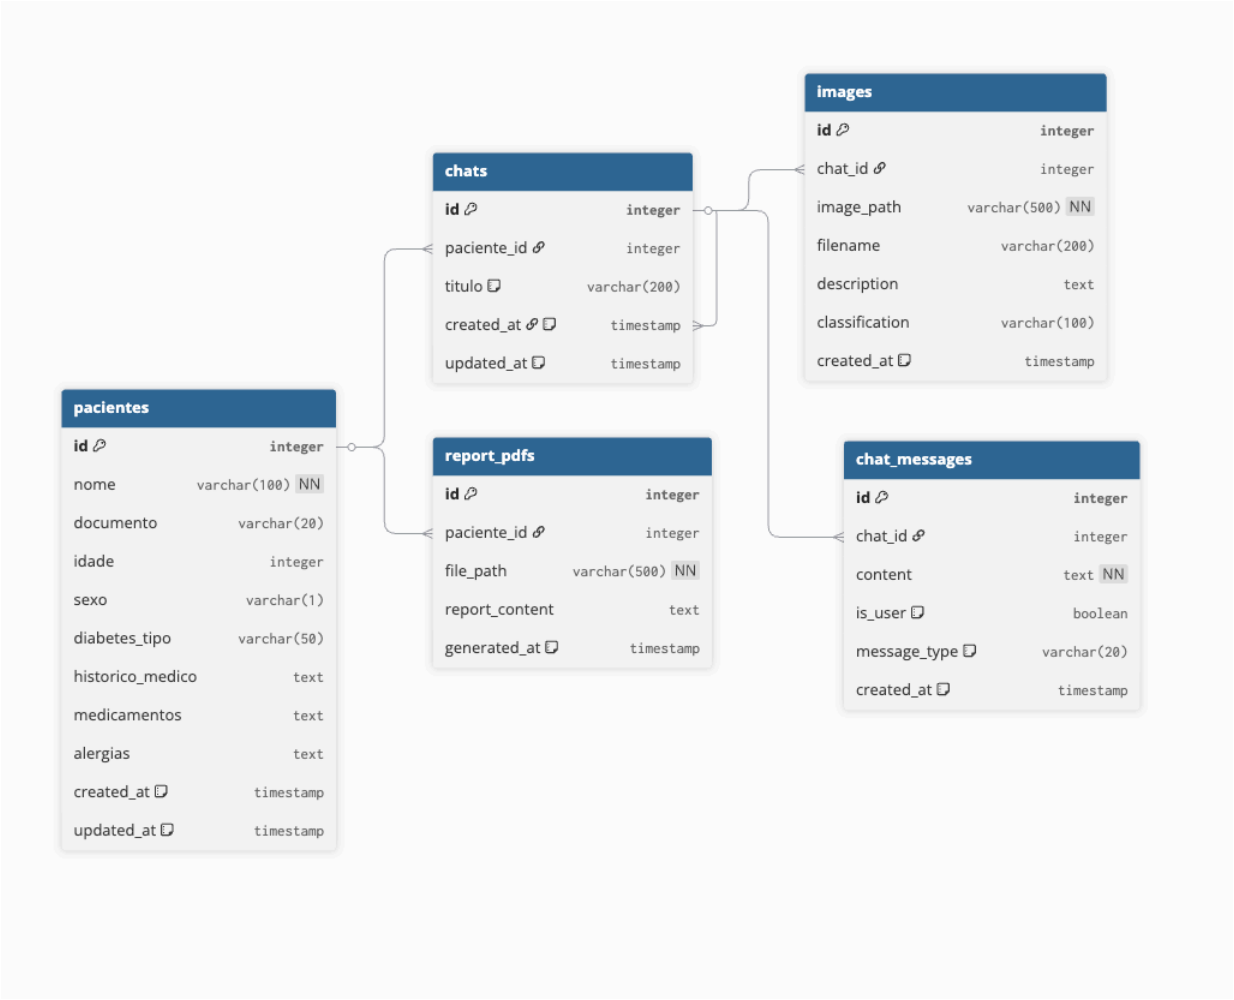

Imagem 4: Diagrama do Banco de dados

A aplicação foi concebida com base em um conjunto de histórias de usuário. Entre as principais funcionalidades implementadas, destacamos:

- Acesso à plataforma via celular, tablet ou computador;
- Busca e filtragem por nome ou documento do paciente;
- Cadastro de novos pacientes, com a possibilidade de envio de imagens diretamente da galeria do dispositivo ou capturadas pela câmera;
- Visualização de informações clínicas e demográficas, histórico de atendimento e status de processamento;
- Classificação automática das imagens de lesões;
- Geração de pré-laudo automatizado, com possibilidade de revisão pelo operador;
- Interação em linguagem natural com um modelo LLM, capaz de responder perguntas, contextualizar casos e gerar relatórios explicativos sobre as predições do modelo de

classificação.

A implantação dos serviços foi realizada via *Docker Compose*, que definiu a orquestração dos contêineres. O serviço *backend* foi responsável pela comunicação com o banco de dados e pelo controle das tarefas distribuídas, enquanto os módulos *Streamlit* e *Worker* executaram as funções de interface e processamento, respectivamente. Cada contêiner foi configurado a partir de imagens base do Python 3.10-slim, garantindo leveza e compatibilidade. O uso de volumes e variáveis de ambiente permitiu persistência dos dados e flexibilidade na configuração de credenciais e caminhos de armazenamento.

A aplicação utilizou um conjunto robusto de bibliotecas Python, incluindo: TensorFlow (2.12.0) para inferência do modelo de classificação; Celery (5.3.4) e Redis (5.0.1) para gerenciamento de tarefas assíncronas; SQLAlchemy (2.0.23) e Psycopg2 (2.9.7) para manipulação do banco de dados; Streamlit (1.50.0) para construção da interface gráfica; ReportLab (4.0.7) para geração de relatórios em PDF; Pandas, NumPy e Pillow para manipulação de dados e imagens; e Google GenAI (1.46.0) para integração com o modelo LLM.

O LLM (Large Language Model) foi integrado como camada interpretativa do sistema, responsável por tornar as predições do modelo de classificação explicáveis e contextualizadas. Após a classificação automática de uma imagem, o LLM é acionado com o resultado da rede neural e informações clínicas do paciente, gerando um pré-laudo textual interpretável, com justificativas em linguagem natural e sugestões para acompanhamento clínico. Essa abordagem promove transparência e confiabilidade, permitindo que profissionais de saúde compreendam por que o sistema associou uma imagem a determinada categoria de lesão.

Por fim, configuramos a aplicação para gerar relatórios consolidados em formato PDF, agregando as imagens originais, as previsões do modelo, os resumos explicativos do LLM e o histórico de interações. Esse conjunto de funcionalidades possibilitou a criação de uma ferramenta prática e explicável para suporte à decisão clínica, conciliando visão computacional e processamento de linguagem natural em um mesmo fluxo operacional.

3. RESULTADOS

3.1. Modelo de Classificação

Como vimos anteriormente, foram realizadas três etapas principais de treinamento e avaliação antes da construção do software para desenvolvimento do modelo de classificação, cada etapa informando a decisão da etapa seguinte: (i) treinamento com Transfer Learning (TL) por 50 épocas; (ii) extensão do treinamento até 94 épocas; e (iii) fine-tuning descongelando as últimas camadas da VGG16. Em todos os experimentos utilizamos validação por conjunto de teste separado e monitoramento por callbacks (checkpoint + early stopping) sobre a acurácia de validação.

3.1.1. Treinamento com Transfer Learning (TL) por 50 Épocas

No primeiro ciclo, limitámos o ajuste às camadas adicionadas ao topo da VGG16, mantendo congelada a base convolucional. Após 50 épocas observámos um comportamento de aprendizagem com melhora consistente na métrica de validação.

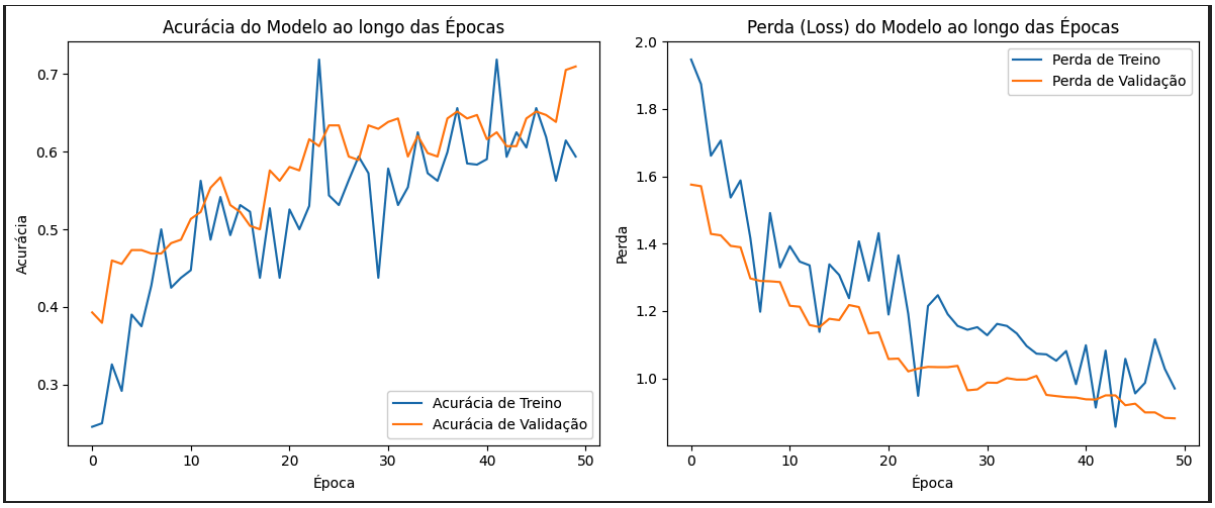

Imagem 5: Acurácia (esquerda) e Perda (direita) do modelo ao logo das épocas para o modelo Baseline

As curvas de acurácia e perda exibiram tendência de melhoria, sem indícios claros de *overfitting*. A acurácia global obtida neste estágio foi 72,22%.

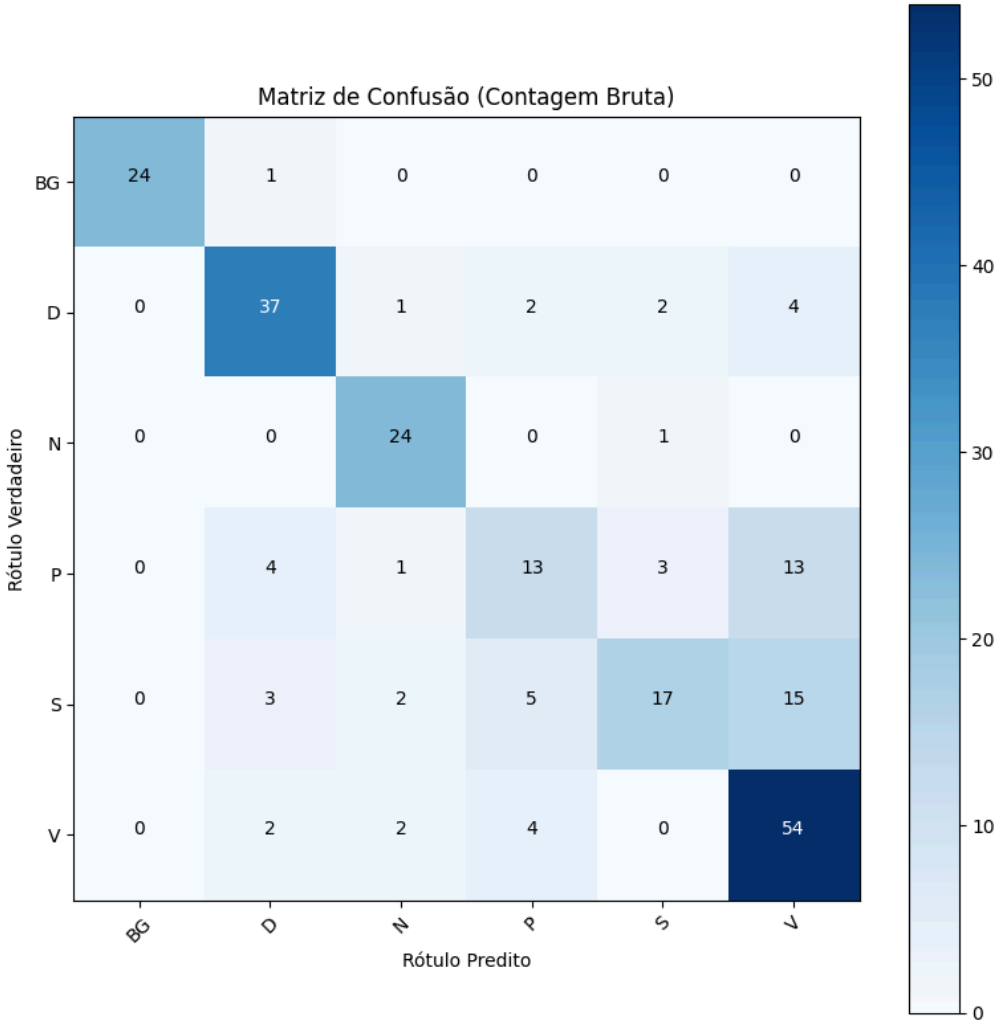

Imagem 6: Matriz de Confusão

A matriz de confusão acima e as métricas agragadas na tabela abaixo indicaram bom desempenho para classes como BG (Fundo), D (Diabética) e N (Pele Normal), e dificuldades relativas para P (Pressão) e S (Cirúrgica), que frequentemente foram confundidas com V (Venosa). Métricas agregadas (baseline 50 épocas):

Classe	Precision	Recall	F1-Score
BG	1.00	0.96	0.98
D	0.79	0.80	0.80
N	0.80	0.96	0.87
V	0.63	0.87	0.73
S	0.74	0.40	0.52
P	0.54	0.38	0.45

A análise da matriz de confusão mostrou, por exemplo, que das 34 amostras reais de P, 13 foram corretamente classificadas, enquanto 13 foram classificadas como V e 4 como D. Evidência de sobreposição nas features visuais entre essas classes.

3.1.2. Extensão do Treinamento até 94 Épocas

Dado o comportamento ascendente das curvas de validação ao final do primeiro ciclo, estendemos o treinamento por mais 50 épocas. O processo foi interrompido por *early stopping* na época 94 (segunda rodada, patience = 10), com restauração dos melhores pesos observados ao longo das 94 épocas. Esse segundo ciclo aumentou a acurácia global para 74,79%.

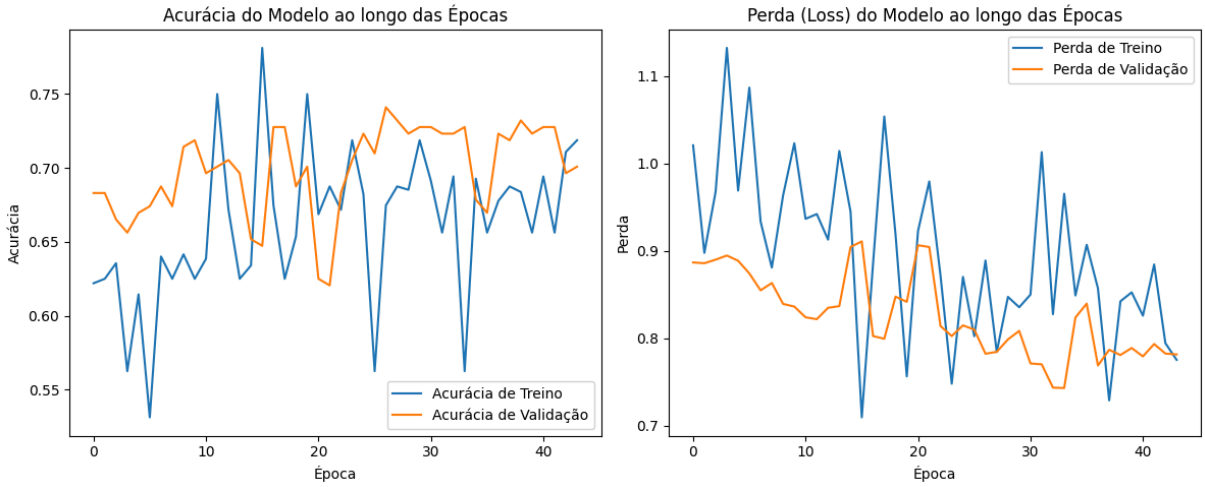

Imagem 7: Acurácia (esquerda) e Perda (direita) do modelo ao logo das épocas para o modelo File-Tuned

As curvas de acurácia mostraram que a acurácia de validação manteve-se superior à acurácia de treino na segunda metade do treinamento, o que sugeriu boa capacidade de generalização do modelo treinado via *Transfer Learning.*

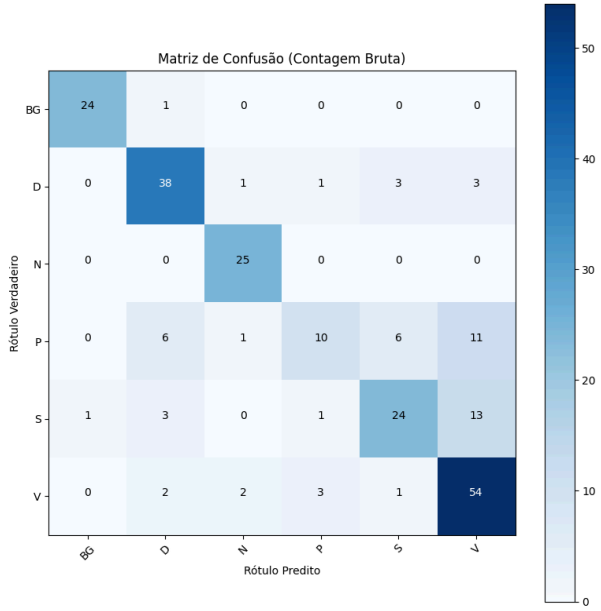

Imagem 8: Matriz de Confusão

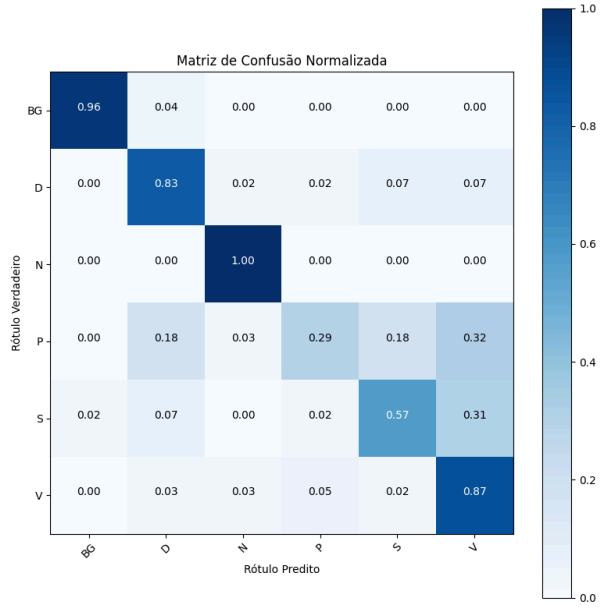

Imagem 9: Matriz de Confusão Normalizada

A matriz de confusão normalizada após o segundo ciclo nos mostra que a classe P continuou sendo o principal ponto fraco: das 34 amostras reais de P o modelo passou a acertar apenas 10, classificando erroneamente a maioria como V, S ou D. Em suma, a extensão do ciclo melhorou a acurácia global e a robustez geral do classificador, mas não solucionou a confusão entre P e as demais lesões.

3.1.3. Fine-Tuning Descongelando as Últimas Camadas da VGG16

Para atenuar a confusão específica entre classes visualmente semelhantes, descongelamos o último bloco convolucional (*block5*) da VGG16 e recompilamos o modelo com uma taxa de aprendizado muito baixa ($LR \approx 1e^{-5}$). Ajustámos então apenas as últimas camadas convolucionais em conjunto com o topo já treinado, usando callbacks com *patience* reduzido (5 épocas) dada a sensibilidade do fine-tuning. O ciclo de fine-tuning foi definido para até 20 épocas e foi interrompido na época 13 por *early stopping*.

Métrica	Baseline (74.79%)	Fine-Tuned (75.21%)	Mudança
Acurácia Global	0.7479	0.7521	+0.42%
Recall (P)	0.2941	0.2647	-2.94%
F1-Score (P)	0.41	0.38	-0.03
Recall (V)	0.8709	0.9516	+8.07%

O *fine-tuning* resultou em uma melhora marginal da acurácia global, que passou de 74,79%

(melhor ponto do TL estendido) para 75,21% no modelo *fine-tuned*. No entanto, a análise por classe revelou diferenças importantes de comportamento: o *recall* da classe V (Venosa) aumentou de 87.09% para 95.16%, enquanto o *recall* da classe P (Pressão) caiu de 29.41% para 26.47%.

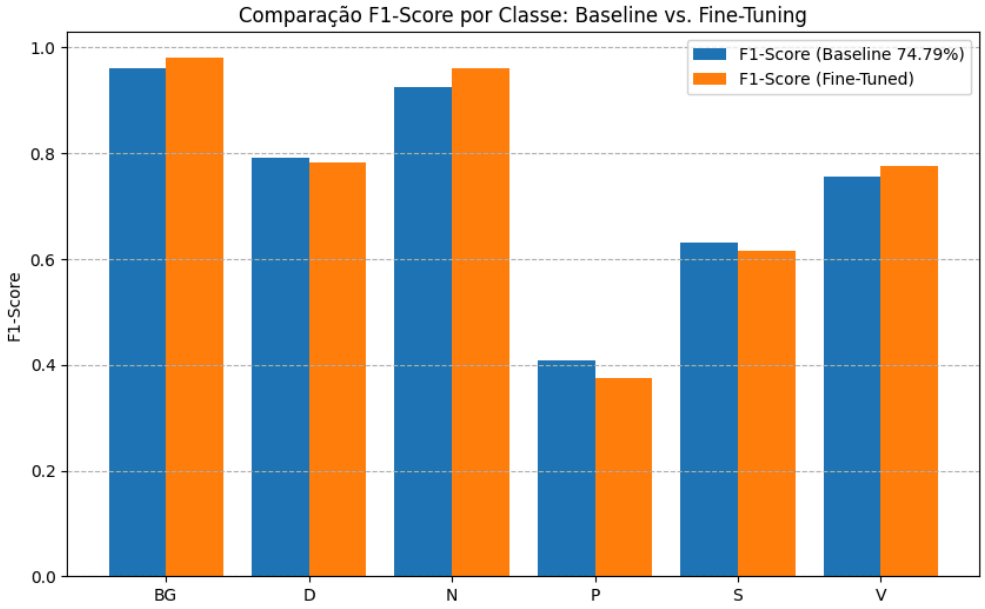

Imagem 10: Comparação F1-Score por Classe: Baseline vs. Fine-Runing

O *F1-score* da classe P também apresentou queda (≈ 0.41 → 0.38). Em outras palavras, o *fine-tuning* levou o modelo a melhorar substancialmente a identificação de úlceras venosas, ao custo de uma piora na detecção de úlceras por pressão.

3.1.4. Procedimentos de Exportação e Decisão Operacional

Em síntese quantitativa, estamos falando dos seguintes resultados abaixo:

Etapa	Acurácia Global	Interpretação
TL (50 ep.)	72.22%	Baseline Inicial
TL estendido (até 94 ep.)	74.79%	Melhor modelo sem Fine-Tuning
Fine-Tuning (block5, $LR \approx 1e^{-5}$)	75.21%	Melhora global marginal; redistribuição de performance entre classes

O uso de Transfer Learning mostrou-se eficaz para obter um classificador robusto com recursos limitados de dados, permitindo ganhos rápidos de acurácia e boa generalização quando comparado a treinamento do zero. A extensão do treinamento (segundo ciclo) produziu ganho substancial de acurácia sem sinais de overfitting, justificando que a rede ainda podia assimilar informação útil após 50 épocas iniciais. O fine-tuning procurou especializar os extratores de alto nível para diferenciar

classes limítrofes; obteve-se um ganho global modesto, porém com trade-offs importantes por classe, sobretudo a piora do recall de P, que no contexto clínico é crítica, pois representa a possibilidade de perder casos reais de úlcera por pressão. A matriz de confusão e as métricas por classe convergem para a mesma conclusão: P é a classe com desempenho mais fraco e é frequentemente confundida com V, S e D, indicando que as features discriminativas entre essas lesões são sutis e/ou insuficientemente representadas no dataset.

3.2. O Sistema de Análise de Lesões

Tomando isso como base, exportamos as versões treinadas do modelo (baseline TL e fine-tuned) em formato .h5 para integração no IA-CDSS. Dada a melhora global de acurácia e o aumento substancial do recall de V no modelo fine-tuned, optámos por adotar o modelo fine-tuned como versão de produção, com a observação operacional de tratar os resultados referentes à classe P com cautela. Isto é, incorporar regras de apresentação (*thresholding*), avisos explícitos na interface e priorização de revisão humana/LLM quando o modelo prever outras classes em imagens suspeitas de P.

A seguir, apresentamos alguns exemplos das telas desenvolvidas na aplicação, que ilustram as principais funcionalidades do sistema.

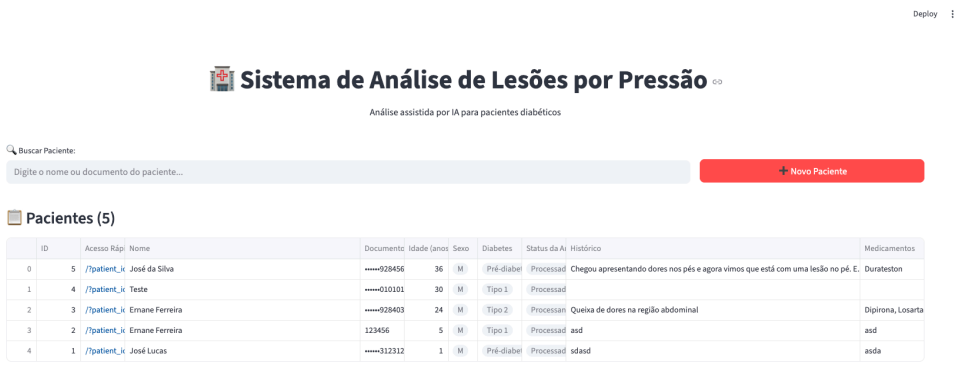

Imagem 11: Tela inicial - Listagem de Pacientes Existentes

A Figura 10 mostra a tela inicial com a listagem de pacientes existentes, onde é possível visualizar informações básicas e acessar os respectivos prontuários.

Imagem 12: Formulário de Cadastro de Novo Paciente - Informações Básicas

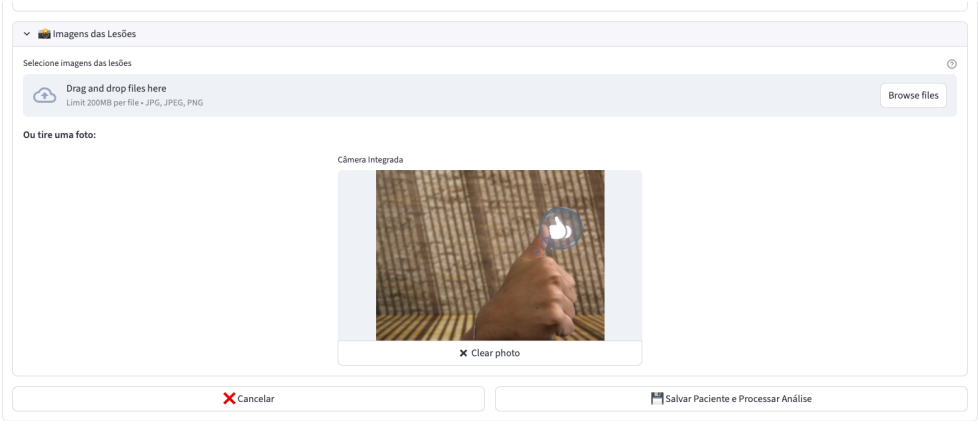

Imagem 13: Formulário de Cadastro de Novo Paciente - Imagens das Lesões

A Figura 11 apresenta o formulário de cadastro de um novo paciente, contendo os campos de identificação e dados clínicos essenciais. Em sequência, a Figura 12 exibe a etapa de anexação das imagens das lesões, permitindo o envio direto a partir da galeria ou da câmera do dispositivo.

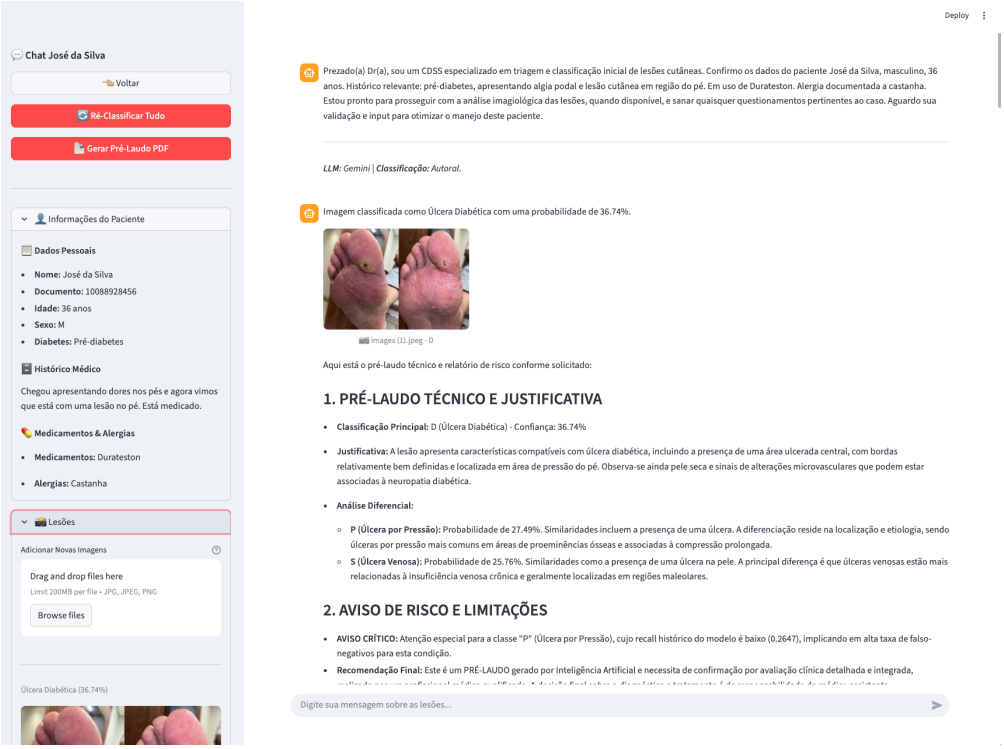

Imagem 14: Tela de Chat de Um Paciente Aberta

A Figura 13 demonstra a interface de chat de um paciente, que integra o histórico clínico, as imagens processadas e as interações com o modelo de IA.

PRÉ-LAUDO MÉDICO - ANÁLISE DE LESÕES
Sistema de IA de Suporte à Decisão Clínica (IA-CDSS)

Data de emissão: 07/11/2025 às 17:28

Antonio de Oliveira - Mestrando
Ernane Ferreira - Mestrando
Prof. Dr. Ricardo Valentim

1. INFORMAÇÕES DO PACIENTE

Nome: José da Silva
Idade: 36 anos
Sexo: M
Tipo de Diabetes: Pré-diabetes
Documento: 10088928456
Histórico Médico: Chegou apresentando dores nos pés e agora vimos que está com uma lesão no pé. Está medicado.
Medicamentos: Durateston
Alergias: Castanha

2. ANÁLISE DAS LESÕES

2.1 Lesão 1:

Classificação: D - Úlcera Diabética (36.74%)
Arquivo: images (1).jpeg
Distribuição de Probabilidades:

Classificação	Probabilidade	Descrição
D	36.74%	Úlcera Diabética
P	27.49%	Úlcera por Pressão
S	25.76%	Ferida Cirúrgica

Imagem 15: Exemplo de pré-laudo (pdf) gerado - Página 1

V	9.43%	Úlcera Venosa

Análise Formal:

Ao exame da região plantar, observa-se lesão ulcerada, circunscrita, com bordas definidas e halo eritematoso. A lesão apresenta profundidade moderada e exsudato seroso discreto. A classificação primária, com confiança de 36.74%, sugere etiologia de úlcera diabética (Classe D), com probabilidade de 100%. Contudo, devido à baixa confiança do modelo, é imprescindível considerar diagnósticos diferenciais, incluindo úlcera por pressão, úlcera venosa e lesões infecciosas. Recomenda-se avaliação clínica completa e exames complementares para confirmação diagnóstica e planejamento terapêutico adequado.

2.2 Lesão 2:

Classificação: S - Ferida Cirúrgica (49.84%)
Arquivo: 19_1.jpg
Distribuição de Probabilidades:

Classificação	Probabilidade	Descrição
S	49.84%	Ferida Cirúrgica
D	10.39%	Úlcera Diabética
N	4.90%	Pele Normal
BG	3.24%	Background

Análise Formal:

Laudo Descritivo: A imagem analisada demonstra a presença de uma lesão cutânea linear, caracterizada por bordas aproximadas e presença de suturas. A morfologia sugere fortemente tratar-se de uma ferida cirúrgica recente. A classificação automática da imagem indica "Ferida Cirúrgica" (Classe S), com um nível de confiança de 49.84%. Apesar da probabilidade de 100% para a classe S, o nível de confiança relativamente baixo exige cautela. Considerando os diagnósticos diferenciais, e devido à baixa confiança, outras etiologias de lesões lineares, como lacerações traumáticas ou incisões autoprovocadas, devem ser consideradas e correlacionadas com o histórico clínico do paciente. Recomenda-se avaliação clínica completa para confirmação diagnóstica.

3. INFORMAÇÕES DO SISTEMA

Desempenho do Modelo de Classificação:

Glossário de Métricas:
- **Precision**: Acerto nas previsões positivas (exatidão)
- **Recall**: Capacidade de encontrar todos os casos positivos (sensibilidade)

Imagem 16: Exemplo de pré-laudo (pdf) gerado - Página 2

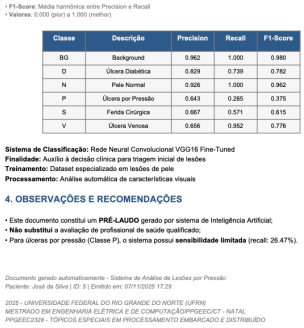

- **F1-Score**: Média harmônica entre Precision e Recall
- **Valores**: 0.000 (pior) a 1.000 (melhor)

Classe	Descrição	Precision	Recall	F1-Score
BG	Background	0.962	1.000	0.980
D	Úlcera Diabética	0.829	0.739	0.782
N	Pele Normal	0.926	1.000	0.962
P	Úlcera por Pressão	0.643	0.265	0.375
S	Ferida Cirúrgica	0.667	0.571	0.615
V	Úlcera Venosa	0.656	0.952	0.776

Sistema de Classificação: Rede Neural Convolucional VGG16 Fine-Tuned
Finalidade: Auxílio à decisão clínica para triagem inicial de lesões
Treinamento: Dataset especializado em lesões de pele
Processamento: Análise automática de características visuais

4. OBSERVAÇÕES E RECOMENDAÇÕES

- Este documento constitui um **PRÉ-LAUDO** gerado por sistema de Inteligência Artificial;
- **Não substitui** a avaliação de profissional de saúde qualificado;
- Para úlceras por pressão (Classe P), o sistema possui **sensibilidade limitada** (recall: 26.47%).

Documento gerado automaticamente - Sistema de Análise de Lesões por Pressão
Paciente: José da Silva | ID: 5 | Emitido em: 07/11/2025 17:29

2025 - UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE (UFRN)
MESTRADO EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO:PPGEEC/CT - NATAL
PPGEEC2328 - TÓPICOS ESPECIAIS EM PROCESSAMENTO EMBARCADO E DISTRIBUÍDO

Imagem 17: Exemplo de pré-laudo (pdf) gerado - Página 3

Por fim, as Figuras 14, 15 e 16 ilustram o pré-laudo em formato PDF gerado automaticamente pelo sistema, apresentando as informações consolidadas, classificações das lesões e o resumo interpretativo produzido pelo modelo de linguagem (LLM).

4. CONSLUSÃO

O presente trabalho demonstrou a viabilidade do uso de redes neurais convolucionais (CNN) combinadas a técnicas de *Transfer Learning* para a classificação automática de feridas crônicas em imagens clínicas. A arquitetura VGG16, ajustada e posteriormente refinada via *Fine-Tuning*, apresentou desempenho consistente, alcançando acurácia global de 75,21% e evidenciando boa capacidade de generalização, especialmente nas classes com maior representatividade no conjunto de dados. Embora a detecção de úlceras por pressão ainda represente um desafio, reflexo da semelhança visual entre as classes e da limitação amostral, os resultados obtidos indicam que a abordagem proposta é promissora como base para sistemas de apoio ao diagnóstico.

Além do modelo em si, desenvolvemos uma aplicação completa de suporte à decisão clínica (IA-CDSS), integrando o classificador de lesões com um modelo de linguagem (LLM) para geração de explicações interpretáveis e pré-laudos automáticos. A plataforma foi projetada com foco em usabilidade e escalabilidade, incorporando módulos independentes para *backend*, processamento assíncrono e interface interativa via *Streamlit*. Essa integração entre IA explicável e processamento clínico automatizado representa um avanço significativo em direção a soluções práticas e transparentes para o acompanhamento de pacientes com feridas crônicas.

5. REFERÊNCIAS

- Patel, Y., Shah, T., Mrinal Kanti Dhar, Zhang, T., Niezgoda, J., Gopalakrishnan, S., & Yu, Z. (2024). **Integrated image and location analysis for wound classification: a deep learning approach**. Scientific Reports, 14(1). https://doi.org/10.1038/s41598-024-56626-w
- Anisuzzaman, D. M., Patel, Y., Rostami, B., Niezgoda, J., Gopalakrishnan, S., & Yu, Z. (2022). **Multi-modal wound classification using wound image and location by deep neural network**. Scientific Reports, 12(1). https://doi.org/10.1038/s41598-022-21813-0
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). **How transferable are features in deep neural networks? Advances in Neural Information Processing Systems**, 27. https://papers.nips.cc/paper/2014/hash/375c71349b295fbe2dcdca9206f20a06-Abstract.html
- Simonyan, K., & Zisserman, A. (2015). **Very Deep Convolutional Networks for Large-Scale Image Recognition**. International Conference on Learning Representations. https://arxiv.org/abs/1409.1556
- Tan, C., Sun, F., Kong, T., Zhang, W., Yang, C., & Liu, C. (2018). **A Survey on Deep Transfer Learning. Lecture Notes in Computer Science**, 11141, 270–279. https://doi.org/10.1007/978-3-030-01424-7_27
- Merkel, D. (2014). **Docker: Lightweight Linux Containers for Consistent Development and Deployment**. Linux Journal, 2014(239), 2. https://www.linuxjournal.com/content/docker-lightweight-linux-containers-consistent-development-and-deployment
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). **Gradient-Based Learning Applied to Document Recognition**. Proceedings of the IEEE, 86(11), 2278–2324. https://doi.org/10.1109/5.726791